Informe de Proyecto No Supervisado: Instrumentos Agrupamiento Tímbrico y Separación Armónico-Percusiva de Señales Acústicas mediante Aprendizaje No Supervisado



Imanol Marcelo Moya Condori y Neytan Alan Quispe Quisbert

Carrera de Informática, Facultad de Ciencias Puras y Naturales, Universidad Mayor de San Andrés

DAT-255: Aprendizaje No Supervisado

M. Sc. Menfy Morales Rios

9 de noviembre de 2026

La Paz, Bolivia, 2026

Repositorio en GitHub: https://github.com/Manolodev-web/Proyecto_No_Supervisado.git

Plataforma web en vivo: https://dat255.netlify.app/

Resumen

Este informe documenta el diseño, la evaluación y el despliegue de un sistema de agrupamiento tímbrico y separación armónico-percusiva de señales acústicas basado exclusivamente en aprendizaje no supervisado clásico, sin redes neuronales. A partir de 2,629 archivos de audio monoaurales se construyó un extractor de 71 descriptores físicos (cociente de energía HPSS, cromagrama Constant-Q, MFCC, contraste espectral y momentos de forma). Una auditoría forense del corpus reveló que los 700 vectores rotulados como *Sound_Violin* eran copias idénticas de *Sound_Drum* y que existían 8 duplicados cruzados adicionales; tras depurar 708 registros quedaron 1,921 muestras de tres familias acústicas genuinas: guitarra (700), percusión (693) y piano (528). La hipótesis inicial de $k = 4$ se descartó y $k = 3$ se adoptó por el pico del coeficiente de silueta (0.2985). Todos los modelos (K-Means++, jerárquico de Ward, mezclas gaussianas, DBSCAN y HDBSCAN) se ajustaron sobre el mismo espacio latente de 15 componentes principales (79.85 % de varianza). K-Means ($k = 3$) obtuvo la mejor cohesión (silueta 0.2985; Calinski-Harabasz 664.71), el GMM el mayor ARI (0.5510) y DBSCAN la mejor separación entre núcleos densos (Davies-Bouldin 1.0903) a costa de 23.27 % de ruido. La percusión se aísla con claridad, mientras que piano y guitarra comparten regiones del espacio acústico. Los modelos se integraron en una API Flask con aislamiento de sesiones, ventaneo temporal de 1.5 s y descarga de los stems armónico y percusivo. Se justifica por qué no se implementó separación de voz y se proponen NMF semi-supervisada y autoencoders variacionales como trabajo futuro.

Palabras clave: aprendizaje no supervisado, recuperación de información musical, HPSS, transformada Constant-Q, K-Means, modelos de mezclas gaussianas, HDBSCAN, UMAP

Índice General

Resumen

1. Introducción

2. Objetivos

    2.1. Objetivo general

    2.2. Objetivos específicos

3. Marco Teórico

    3.1. Fundamentos del audio digital y la STFT

    3.2. Separación armónico-percusiva (HPSS)

    3.3. Transformada Constant-Q y cromagrama

    3.4. Espacio de características de 71 dimensiones

    3.5. Reducción ortogonal mediante PCA

    3.6. Fundamentos de los modelos no supervisados

    3.7. Métricas de evaluación

4. Marco Práctico y Desarrollo

    4.1. Estructura del repositorio y flujo secuencial

    4.2. Módulo canónico de extracción

    4.3. Auditoría forense y deduplicación

    4.4. Pipeline secuencial de modelado

    4.5. Consolidación de métricas

    4.6. Inferencia por línea de comandos

    4.7. Arquitectura de la plataforma web

5. Conclusiones y Recomendaciones

    5.1. Conclusiones

    5.2. Limitaciones

    5.3. Justificación metodológica: por qué no se separó la voz

    5.4. Recomendaciones y trabajo futuro

6. Bibliografía

7. Anexos

    Anexo A. Evidencia experimental y gráficos generados

    Anexo B. Evidencias de la plataforma web en producción

1. Introducción

La Recuperación de Información Musical (*Music Information Retrieval*, MIR) es un campo interdisciplinario que integra el procesamiento digital de señales, la acústica, la psicoacústica y el aprendizaje automático para analizar, segmentar y categorizar eventos sonoros de forma sistemática (Müller, 2015). Sus aplicaciones abarcan desde la transcripción armónica y el etiquetado automático de instrumentos hasta los sistemas de recomendación y la separación de fuentes. Tradicionalmente, la clasificación de timbres se ha abordado con modelos supervisados que dependen de grandes volúmenes de anotaciones manuales; sin embargo, en escenarios reales la anotación humana es costosa, inconsistente entre anotadores y susceptible de errores de captura.

El aprendizaje no supervisado ofrece una alternativa matemáticamente transparente. En lugar de memorizar pares de entrada y salida, estos métodos descubren agrupaciones naturales, variedades subyacentes y distribuciones de probabilidad que emergen directamente de las propiedades físicas de la onda: su contenido armónico, su dispersión espectral, su riqueza tímbrica y su comportamiento temporal (Bishop, 2006). Esta transparencia es especialmente valiosa en un contexto académico, pues permite auditar cada decisión del modelo en términos de magnitudes físicas interpretables, algo que las arquitecturas de caja negra dificultan.

El desafío central de la clasificación sin supervisión es que la calidad de una partición no puede verificarse contra una verdad de terreno durante el entrenamiento. Se depende entonces de métricas internas de cohesión y separación, y de métricas externas calculadas *a posteriori* contra las etiquetas nominales. Esta dependencia implica que cualquier defecto en las etiquetas contamina directamente la evaluación. La separación de fuentes, por su parte, plantea una dificultad adicional: separar instrumentos superpuestos sin ejemplos supervisados exige

supuestos fuertes sobre la estructura de la señal, como los que hace el algoritmo HPSS al distinguir componentes estacionarias de transitorias (FitzGerald, 2010).

El **planteamiento del problema** de este proyecto surgió de una anomalía empírica. Al analizar las matrices de contingencia de los primeros modelos con $k = 4$ (guitarra, percusión, violín y piano), las filas de *Sound_Drum* y *Sound_Violin* resultaron idénticas en todos los algoritmos. Una auditoría matricial confirmó que los 700 vectores de violín eran copias exactas de los 700 de percusión. La consecuencia es doble: el espacio acústico real contiene tres familias y no cuatro, y cualquier métrica externa calculada contra cuatro etiquetas queda acotada por un techo teórico inferior a 1. Este informe documenta la detección del problema, la transición de un $k = 4$ artificial a un $k = 3$ físicamente justificado, la reconstrucción completa del pipeline sobre datos saneados y el despliegue de una plataforma web que explota los modelos resultantes.

2. Objetivos

2.1. Objetivo general

Desarrollar el marco experimental, analítico y computacional para el agrupamiento y la separación de fuentes acústicas no supervisadas, fundamentado en descriptores físicos de la señal, reducción dimensional ortogonal y algoritmos clásicos de agrupamiento, y desplegado como una plataforma web interactiva.

2.2. Objetivos específicos

1. Implementar un extractor físico-acústico de 71 variables (HPSS, cromagrama CQT, MFCC, contraste espectral y momentos de forma) en un módulo canónico único, compartido por el procesamiento por lotes, la inferencia por consola y la API web.
2. Realizar una auditoría forense del corpus que detecte duplicados y etiquetas inconsistentes, y generar un conjunto saneado de muestras únicas.

3. Calibrar un espacio latente unificado de 15 componentes principales sobre el que se ajusten y evalúen todos los modelos.
4. Ejecutar un benchmark comparativo de K-Means++, clustering jerárquico de Ward, GMM, DBSCAN y HDBSCAN con métricas internas (silueta, Calinski-Harabasz, Davies-Bouldin) y externas (ARI y NMI), además de contrastar cinco técnicas de reducción dimensional (PCA, SVD truncada, Factor Analysis, t-SNE y UMAP).
5. Construir y desplegar una plataforma interactiva que realice inferencia tímbrica por ventanas, detección de notas dominantes y descarga de los stems armónico y percusivo.

3. Marco Teórico

3.1. Fundamentos del audio digital y la STFT

Una señal de audio digital es una secuencia discreta de muestras $x[n] = x(nT_s)$, donde $T_s = 1/f_s$ es el período de muestreo. En este proyecto todas las señales se remuestrean a $f_s = 22{,}050$ Hz y se convierten a mono. La forma de onda cruda codifica únicamente variaciones de presión en el tiempo y resulta inadecuada para comparaciones por distancia euclidiana, por su sensibilidad al desfase y a la forma de onda particular de cada grabación. Por ello la señal se transporta al dominio tiempo-frecuencia mediante la Transformada Corta de Fourier (STFT):

$$X[m, \omega] = \sum_{n=-\infty}^{\infty} x\,[n]\, w[n - m]\, e^{-j\omega n}$$

donde $w[\cdot]$ es una ventana (por ejemplo, de Hann). El espectrograma de magnitud $S(t, f) = |X(t, f)|$ es la representación sobre la cual operan HPSS y la mayoría de los descriptores. La resolución de la STFT está limitada por el principio de incertidumbre tiempo-

frecuencia: una ventana larga mejora la resolución frecuencial pero degrada la temporal, y viceversa, con un ancho de banda uniforme en todo el espectro.

3.2. Separación armónico-percusiva (HPSS)

HPSS descompone el espectrograma de magnitud en dos componentes aditivas, una armónica y una percusiva (FitzGerald, 2010):

$$S(t,f) \approx H(t,f) + P(t,f)$$

La componente armónica H agrupa los sonidos sostenidos (cuerdas, tubos, voz sonora), que aparecen como trayectorias horizontales de frecuencia constante. La componente percusiva P agrupa los transitorios (golpes, platillos, consonantes oclusivas), que aparecen como ráfagas verticales de banda ancha. Ambas se estiman mediante filtros de mediana en direcciones ortogonales:

$$\tilde{H}(t,f) = \mathcal{M}_t\{S(t,f);\, l_{\text{harm}}\}, \qquad \tilde{P}(t,f) = \mathcal{M}_f\{S(t,f);\, l_{\text{perc}}\}$$

donde $\mathcal{M}_t$ es la mediana móvil a lo largo del eje temporal y $\mathcal{M}_f$ a lo largo del eje frecuencial. La asignación de energía se realiza con máscaras suaves de tipo Wiener:

$$M_H = \frac{\tilde{H}^2}{\tilde{H}^2 + \tilde{P}^2 + \epsilon}, \qquad M_P = \frac{\tilde{P}^2}{\tilde{H}^2 + \tilde{P}^2 + \epsilon}$$

Las señales temporales y_{harm} y y_{perc} se reconstruyen aplicando las máscaras sobre la STFT original y la transformada inversa (ISTFT), conservando la fase. A partir de ellas se define el cociente de energía normalizado, una de las 71 variables:

$$\rho_{\text{HPSS}} = \frac{E_{\text{perc}} - E_{\text{harm}}}{E_{\text{perc}} + E_{\text{harm}}}, \qquad E_{\bullet} = \sum_n y_{\bullet}[n]^2, \quad \rho_{\text{HPSS}} \in [-1,1]$$

Valores cercanos a $+1$ indican señales dominadas por transitorios (percusión) y cercanos a -1 señales dominadas por componentes tonales sostenidas.

3.3. Transformada Constant-Q y cromagrama

En la música occidental el tono evoluciona logarítmicamente con la frecuencia: $f_k = f_{\min} \cdot 2^{k/B}$, con $B = 12$ semitonos por octava. En graves, dos notas contiguas distan pocos hercios, mientras que en agudos distan cientos, de modo que una resolución frecuencial uniforme como la de la STFT es inadecuada. La Transformada Constant-Q (Brown, 1991) mantiene constante la razón entre la frecuencia central y el ancho de banda de cada filtro:

$$Q = \frac{f_k}{\Delta f_k} = \left(2^{1/B} - 1\right)^{-1} \approx 16.82 \quad (B = 12)$$

La longitud de ventana de cada bin se adapta a su frecuencia, $N_k = Q\, f_s / f_k$, y la transformada resulta:

$$X^{\mathrm{cq}}[k, n] = \frac{1}{N_k} \sum_{j=0}^{N_k - 1} x\,[n + j]\, w_{N_k}[j]\, e^{-j 2\pi Q j / N_k}$$

Para obtener el **cromagrama**, la energía de todos los bins que comparten la misma clase de tono (la misma nota en distintas octavas) se agrega en un vector de 12 dimensiones:

$$C(p, t) = \sum_{o} \left| X^{\mathrm{cq}}[p + 12\, o,\ t] \right|, \qquad p \in \{\mathrm{C}, \mathrm{C\sharp}, \mathrm{D}, \ldots, \mathrm{B}\}$$

En este proyecto el cromagrama se calcula sobre la componente armónica y_{harm}, de modo que los transitorios percusivos no contaminen la estimación de las notas dominantes (Müller, 2015).

3.4. Espacio de características de 71 dimensiones

Cada archivo de audio se resume en un vector $\mathbf{x} \in \mathbb{R}^{71}$ cuya composición se detalla en la Tabla 1. Cada descriptor definido por cuadros se resume con su media y su desviación estándar a lo largo del tiempo.

Tabla 1
Composición del vector acústico de 71 dimensiones

Dominio físico	Descriptor	Dimensiones
Envolvente tímbrica	MFCC, coeficientes 0 a 12 (media y desviación)	26
Tonalidad armónica	Cromagrama CQT de 12 notas (media y desviación)	24
Dinámica espectral	Contraste espectral, 7 filas (media y desviación)	14
Centroide	Centroide espectral (media y desviación)	2
Límite energético	Rolloff al 85 % (media y desviación)	2
Dominio temporal	Tasa de cruce por cero (media y desviación)	2
Física de fuentes	Cociente de energía HPSS	1
Total		**71**

Nota. El contraste espectral con seis bandas devuelve siete filas (seis bandas más la banda residual), de ahí sus 14 variables. Fuente: elaboración propia a partir de `01_features/audio_features.py`.

Los **coeficientes cepstrales en las frecuencias de Mel** (MFCC) capturan la envolvente espectral, que es el correlato acústico del timbre (Davis y Mermelstein, 1980). Se calcula la energía E_m de M filtros triangulares espaciados en la escala Mel, $m(f) = 2595\log_{10}(1 + f/700)$, y se aplica la transformada de coseno discreta:

$$c_n = \sum_{m=1}^{M} \log(E_m)\cos\left[\frac{\pi n}{M}(m - 1/2)\right], \qquad n = 0, \ldots, 12$$

El **centroide espectral** es el centro de masa de la distribución de frecuencias y correlaciona con el brillo percibido, $\mu_t = \sum_f f\ S(t,f) / \sum_f S(t,f)$. El **rolloff** al 85 % es la frecuencia f_R bajo la cual se acumula el 85 % de la energía espectral. La **tasa de cruce por cero** es $\mathrm{ZCR} = \frac{1}{N-1}\sum_{n=1}^{N-1} \mathbb{1}\{x[n]\,x[n-1] < 0\}$ y distingue señales ruidosas o percusivas de tonos sostenidos. El **contraste espectral** mide, en decibelios, la diferencia entre picos y valles de energía en bandas de frecuencia, lo que separa los armónicos resonantes estrechos del ruido distribuido.

3.5. Reducción ortogonal mediante PCA

Las 71 variables poseen escalas muy distintas (el rolloff se mide en miles de hercios y el cociente HPSS en $[-1,1]$), por lo que se estandarizan mediante la puntuación z, $z_{ij} = \left(x_{ij} - \bar{x}_j\right)/s_j$. Sobre la matriz estandarizada $\mathbf{Z} \in \mathbb{R}^{n\times 71}$ se calcula la matriz de covarianza y su descomposición espectral:

$$\mathbf{\Sigma} = \frac{1}{n-1}\mathbf{Z}^\top\mathbf{Z} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top, \qquad \mathbf{Y} = \mathbf{Z}\mathbf{V}_k$$

donde las columnas de $\mathbf{V}$ son los componentes principales ordenados por autovalor decreciente (Jolliffe y Cadima, 2016). La varianza explicada acumulada por las primeras k componentes es $\sum_{i\le k}\lambda_i \,/\, \sum_i \lambda_i$. Se adoptó $k = 15$ por tres razones: retiene el 79.85 % de la varianza, produce un espacio ortogonal en el que la distancia euclidiana es menos sensible a la maldición de la dimensionalidad y permite estimar matrices de covarianza completas estables en el GMM (Pedregosa et al., 2011).

3.6. Fundamentos de los modelos no supervisados

K-Means++. El algoritmo de Lloyd (1982) minimiza la inercia, la suma de las distancias euclidianas al cuadrado de cada punto al centroide de su grupo:

$$J = \sum_{j=1}^{k}\sum_{\mathbf{x}_i\in C_j} \| \mathbf{x}_i - \boldsymbol{\mu}_j \|^2$$

La inicialización K-Means++ (Arthur y Vassilvitskii, 2007) elige el primer centroide al azar y cada uno de los siguientes con probabilidad proporcional al cuadrado de la distancia al centroide más cercano ya elegido, $P(\mathbf{x}) = D(\mathbf{x})^2 / \sum_{\mathbf{x}'} D\,(\mathbf{x}')^2$, lo que dispersa los centroides iniciales y garantiza una cota logarítmica de aproximación respecto del óptimo.

Clustering jerárquico aglomerativo de Ward. Parte de n grupos unitarios y fusiona en cada paso los dos grupos cuya unión minimiza el incremento de la suma de cuadrados intragrupo (Ward, 1963):

$$\Delta\mathrm{ESS}(A,B) = \frac{n_A\, n_B}{n_A + n_B} \parallel \boldsymbol{\mu}_A - \boldsymbol{\mu}_B \parallel^2$$

El resultado es un dendrograma; la altura de cada fusión es la distancia de fusión, y un corte horizontal a un nivel dado determina el número de grupos.

Modelos de mezclas gaussianas (GMM). Se asume que los datos provienen de una combinación convexa de k gaussianas multivariadas:

$$p(\mathbf{x}) = \sum_{j=1}^{k} \pi_j \; \mathcal{N}\big(\mathbf{x} \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j\big), \qquad \sum_j \pi_j = 1$$

Los parámetros se estiman por máxima verosimilitud con el algoritmo de Esperanza-Maximización (Dempster et al., 1977). En el paso E se calculan las responsabilidades $\gamma_{ij} = \pi_j \mathcal{N}\big(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j\big) / \sum_l \pi_l \, \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)$; en el paso M se actualizan $\pi_j = N_j/n$, $\boldsymbol{\mu}_j = \frac{1}{N_j}\sum_i \gamma_{ij}\, \mathbf{x}_i$ y $\boldsymbol{\Sigma}_j = \frac{1}{N_j}\sum_i \gamma_{ij}\, \big(\mathbf{x}_i - \boldsymbol{\mu}_j\big)\big(\mathbf{x}_i - \boldsymbol{\mu}_j\big)^{\mathsf{T}}$, con $N_j = \sum_i \gamma_{ij}$. El número de componentes se selecciona con criterios de información que penalizan la complejidad (Akaike, 1974; Schwarz, 1978):

$$\mathrm{AIC} = 2p - 2\ln\hat{L}, \qquad \mathrm{BIC} = p\ln n - 2\ln\hat{L}$$

donde p es el número de parámetros libres. Con covarianza completa en $d = 15$ dimensiones, $p = k\,d + k\;d(d+1)/2 + (k-1)$, que para $k = 3$ vale 407.

DBSCAN. Define la ε-vecindad $N_\varepsilon(\mathbf{x}) = \{\mathbf{y} : \parallel \mathbf{x} - \mathbf{y} \parallel \leq \varepsilon\}$. Un punto es *núcleo* si $|N_\varepsilon(\mathbf{x})| \geq \mathrm{MinPts}$; un punto es *alcanzable por densidad* si existe una cadena de puntos núcleo que lo conecta; y los puntos no alcanzables se declaran *ruido* (Ester et al., 1996). No requiere especificar k, pero asume una densidad global homogénea.

HDBSCAN. Extiende DBSCAN a densidades variables (Campello et al., 2013). Define la distancia núcleo $d_{\text{core}}(\mathbf{x})$ y la distancia de alcanzabilidad mutua:

$$d_{\text{mreach}}(\mathbf{a}, \mathbf{b}) = \max\{d_{\text{core}}(\mathbf{a}),\ d_{\text{core}}(\mathbf{b}),\ d(\mathbf{a}, \mathbf{b})\}$$

Sobre esta métrica se construye un árbol de expansión mínima, se deriva una jerarquía de componentes y se condensa descartando grupos menores que `min_cluster_size`; los grupos finales son los que maximizan la estabilidad en el árbol condensado.

3.7. Métricas de evaluación

Coeficiente de silueta (Rousseeuw, 1987). Para cada punto, con $a(i)$ la distancia media a los puntos de su grupo y $b(i)$ la menor distancia media a los puntos de otro grupo:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1,1]$$

Índice de Calinski-Harabasz (Caliński y Harabasz, 1974). Razón entre la dispersión intergrupo y la intragrupo, ponderada por grados de libertad; mayor es mejor:

$$\text{CH} = \frac{\text{Tr}(B_k)}{\text{Tr}(W_k)} \cdot \frac{n - k}{k - 1}$$

Índice de Davies-Bouldin (Davies y Bouldin, 1979). Similitud media de cada grupo con su peor competidor; menor es mejor:

$$\text{DB} = \frac{1}{k} \sum_{i=1}^{k} \max_{j \neq i} \frac{\sigma_i + \sigma_j}{d(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)}$$

Índice de Rand Ajustado (Hubert y Arabie, 1985). Concordancia entre dos particiones corregida por azar, con valor esperado 0 para asignaciones aleatorias y 1 para coincidencia perfecta:

$$\text{ARI} = \frac{\text{Index} - \text{Expected Index}}{\text{Max Index} - \text{Expected Index}}$$

Información mutua normalizada (Vinh et al., 2010). Con $I(U;V)$ la información mutua entre la partición obtenida U y las etiquetas V, y $H(\cdot)$ la entropía:

$$\mathrm{NMI}(U,V) = \frac{2\,I(U;V)}{H(U)+H(V)} \in [0,1]$$

Las métricas internas (silueta, CH, DB) no requieren etiquetas y evalúan la geometría de la partición; ARI y NMI evalúan su correspondencia con las etiquetas nominales y, por tanto, son tan fiables como estas.

4. Marco Práctico y Desarrollo

4.1. Estructura del repositorio y flujo secuencial

El repositorio `Proyecto_No_Supervisado` está organizado en módulos numerados que se ejecutan de forma secuencial y determinista (todos los modelos usan `random_state=42`). La Tabla 2 resume la función de cada módulo.

Tabla 2
Módulos del repositorio y su función en el pipeline

Paso	Archivo	Función
01	`01_features/audio_features.py`	Módulo canónico de extracción de 71 variables
02	`01_features/02_clean_dataset.py`	Auditoría forense, deduplicación y corrección de metadatos
03	`02_models/03_kmeans_clustering.py`	K-Means++ con $k = 3$, codo, silueta y serialización
04	`02_models/04_hierarchical.py`	Ward, matriz de enlace y dendrograma
05	`02_models/05_density_dbscan_hdbscan.py`	DBSCAN y HDBSCAN sobre 15D PCA
06	`02_models/06_gmm_probabilistic.py`	GMM, BIC/AIC, soft clustering y exportación web
07	`02_models/07_dim_reduction_benchmark.py`	PCA, SVD, Factor Analysis, t-SNE y UMAP
08	`03_evaluation/08_benchmark_metrics.py`	Consolidación oficial de métricas
09	`04_inference/09_predict_instrument.py`	Inferencia por consola

Paso	Archivo	Función
10	`web_app/app.py`	API Flask y plataforma interactiva

Nota. Los artefactos entrenados (`scaler`, `pca_15d`, `pca_2d`, `gmm_model`, `kmeans_model` y los mapeos de clúster) se serializan con `joblib` en `web_app/models_bundle`.

4.2. Módulo canónico de extracción

Toda la matemática de extracción reside en `01_features/audio_features.py`, en la función `extract_71_audio_features(y, sr)`. El fragmento siguiente muestra su núcleo:

```
def extract_71_audio_features(y, sr=22050):
    # 1. HPSS: separación armónica y percusiva
    y_harm, y_perc = librosa.effects.hpss(y)
    e_h, e_p = np.sum(y_harm**2), np.sum(y_perc**2)
    hpss_ratio = (e_p - e_h) / (e_p + e_h + 1e-9)

    # 2. Cromagrama CQT sobre la componente armónica
    chroma = librosa.feature.chroma_cqt(y=y_harm, sr=sr, n_chroma=12)

    # 3. MFCC, contraste espectral y momentos de forma sobre la señal completa
    mfcc = librosa.feature.mfcc(y=y, sr=sr, n_mfcc=13)
    contrast = librosa.feature.spectral_contrast(y=y, sr=sr, n_bands=6)
    ...
    return np.hstack([mfcc_mean, mfcc_std, chroma_mean, chroma_std,
                      contrast_mean, contrast_std, centroid_stats,
                      rolloff_stats, zcr_stats, hpss_ratio])
```

El constante 10^{-9} en el denominador evita la división por cero ante señales de energía nula. La función devuelve además el cromagrama medio y los stems armónico y percusivo, de modo que la API web reutilice un único cálculo de HPSS.

La justificación de concentrar la extracción en un solo módulo es la **eliminación de la divergencia matemática** entre los tres contextos de uso: el extractor por lotes que genera el conjunto de entrenamiento, la inferencia por línea de comandos y la API web. En una versión previa del proyecto, cada contexto contenía su propia copia de la lógica; una modificación en una de ellas (por ejemplo, un cambio de parámetro en el contraste espectral) habría producido vectores sistemáticamente distintos para el mismo audio, y los modelos entrenados con una versión habrían recibido en producción entradas de otra. Con el módulo compartido, el vector

que entra al `StandardScaler` y al PCA en producción es, por construcción, el mismo que se usó en el entrenamiento.

4.3. Auditoría forense y deduplicación

El corpus original contiene 2,629 muestras distribuidas nominalmente en cuatro clases (700 de guitarra, 700 de percusión, 700 de violín y 529 de piano). El script `01_features/02_clean_dataset.py` realiza la auditoría en cinco pasos:

1. **Carga de la matriz** de 2,629 registros por 71 variables.
2. **Verificación matricial** de que los vectores de *Sound_Drum* y *Sound_Violin* coinciden dentro de una tolerancia estricta, `np.allclose(drum, violin, atol=1e-8)`, que devolvió `True`.
3. **Detección de duplicados cruzados** con `df.duplicated(subset=feat_cols)`, que identificó 708 registros redundantes: los 700 violines más 8 duplicados entre otras clases.
4. **Generación del conjunto limpio** `features_instruments_clean.csv`: se excluye la clase *Sound_Violin* y se eliminan los duplicados restantes conservando la primera aparición.
5. **Corrección de la errata** `Sound_Guiatr` por `Sound_Guitar` en `Metadata_Test.csv`, que afectaba a las 20 muestras de guitarra del conjunto de prueba.

```
drum   = df[df.true_instrument == "Sound_Drum"][feat_cols].values
violin = df[df.true_instrument == "Sound_Violin"][feat_cols].values
print(np.allclose(drum, violin, atol=1e-8))          # True

n_redundantes = df.duplicated(subset=feat_cols, keep="first").sum()   # 708
df_clean = (df[df.true_instrument != "Sound_Violin"]
            .drop_duplicates(subset=feat_cols, keep="first"))        # 1,921 filas
```

Una verificación complementaria mostró que los **nombres de archivo** de ambas clases también coinciden uno a uno (por ejemplo, `04-47367.wav`), de modo que los supuestos violines

son los mismos audios de percusión con otra etiqueta. La Tabla 3 compara la distribución antes y después del saneamiento.

Tabla 3
Distribución de muestras antes y después de la deduplicación

Clase	Corpus original	Corpus saneado
Sound_Guitar	700	700
Sound_Drum	700	693
Sound_Violin	700	0
Sound_Piano	529	528
Total	**2,629**	**1,921**

Nota. Se eliminaron 708 registros redundantes: 700 violines idénticos a la percusión y 8 duplicados cruzados (7 en percusión y 1 en piano).

Techo teórico del ARI. Como los violines son copias de la percusión, una partición perfecta en tres familias solo concordaría parcialmente con las cuatro etiquetas nominales. Se calculó este techo: $\mathrm{ARI}_{\max} = 0.683$. Este valor explica por qué las métricas externas de los primeros experimentos con $k = 4$ (entre 0.35 y 0.40) parecían deficientes: eran la mitad del máximo alcanzable, no la mitad de 1.

Selección de k. Sobre el conjunto saneado y el espacio de 15D PCA se barrió $k \in \{2, \ldots, 8\}$ (Tabla 4). El coeficiente de silueta alcanza su máximo en $k = 3$ (0.2985) y cae de forma marcada en $k = 4$ (0.2476); la inercia decrece de manera suave, sin un codo pronunciado, por lo que el pico de silueta es el criterio determinante. Los criterios BIC y AIC del GMM siguen decreciendo hasta $k = 8$, lo que indica subestructura interna (por ejemplo, subtipos de guitarra y de percusión) y no contradice la elección de tres familias físicas: penalizan insuficientemente un modelo de covarianza completa frente a datos con clústeres no gaussianos.

Tabla 4
Selección del número de grupos sobre el conjunto saneado (15D PCA)

k	Inercia K-Means	Silueta K-Means	BIC (GMM)	AIC (GMM)
2	79,807.1	0.2652	97,567	96,060
3	**64,322.6**	**0.2985**	**93,683**	**91,420**
4	57,090.3	0.2476	92,410	89,391
5	50,927.8	0.2403	88,495	84,719
6	47,549.1	0.2462	88,499	83,967
7	45,214.6	0.2347	87,932	82,644
8	42,892.5	0.2253	87,218	81,174

Nota. Valores recomputados sobre `features_instruments_clean.csv` con `random_state=42`. Véase la Figura A1 para las curvas de codo y silueta y la Figura A3 para BIC/AIC.

4.4. Pipeline secuencial de modelado

Todos los modelos se ajustan sobre las mismas 15 componentes principales ortogonales calculadas a partir de los datos estandarizados, que retienen el 79.85 % de la varianza (PC1 = 24.57 % y PC2 = 15.55 %). Esta decisión unifica el espacio de evaluación y hace comparables las métricas entre algoritmos.

4.4.1. Particional: K-Means (`03_kmeans_clustering.py`)

El script estandariza las variables, ajusta el PCA de 15 y de 2 componentes (este último solo para visualización), barre k entre 2 y 8 para producir las curvas de codo y silueta (Figura A1) y ajusta el modelo definitivo con $k = 3$, inicialización K-Means++ y 25 reinicios. La Tabla 5 presenta la matriz de contingencia frente a las etiquetas nominales.

Tabla 5
Matriz de contingencia de K-Means ($k = 3$)

Clase real	Clúster 0	Clúster 1	Clúster 2	Total
Sound_Drum	**673**	16	4	693
Sound_Guitar	12	432	256	700
Sound_Piano	14	**504**	10	528

Nota. El etiquetado semántico por mayoría (C0 = percusión, C1 = piano, C2 = guitarra) es una asignación *post-hoc* y no interviene en el entrenamiento.

El **aislamiento de las baterías** es nítido: 673 de las 693 muestras de percusión (97.1 %) caen en el clúster 0, y ese clúster contiene solo 26 muestras ajenas. Esto confirma que el cociente HPSS, el ZCR y el contraste espectral separan los transitorios de los sonidos tonales con gran eficacia. En cambio, el clúster 1 mezcla 504 pianos con 432 guitarras, mientras que el clúster 2 contiene solo guitarras (256). Es decir, con $k = 3$ el algoritmo no separa piano de guitarra, sino percusión de instrumentos armónicos, y divide a la guitarra en dos subtipos acústicos. La segunda partición de la guitarra es consistente con la isla aislada de guitarra visible en las proyecciones de la Figura A5 y probablemente refleja diferencias de registro o de técnica (por ejemplo, acordes frente a notas individuales).

4.4.2. Jerárquico: Ward (`04_hierarchical.py`)

El script calcula la matriz de enlace con `scipy.cluster.hierarchy.linkage(X, method="ward")` sobre las 15 componentes, grafica el dendrograma (Figura A2) y corta el árbol en $k = 3$ con `AgglomerativeClustering`, el mismo número de grupos que respalda el pico de silueta, de modo que el corte horizontal del dendrograma deja tres ramas principales. La partición resultante es muy similar a la de K-Means (Tabla 6): 677 de 693 baterías en un mismo clúster, con piano y guitarra mezclados en el clúster 0 y una segunda rama de guitarra en el clúster 2.

Tabla 6
Matriz de contingencia del clustering jerárquico de Ward ($k = 3$)

Clase real	Clúster 0	Clúster 1	Clúster 2
Sound_Drum	7	**677**	9
Sound_Guitar	442	2	256
Sound_Piano	**481**	23	24

4.4.3. Densidad: DBSCAN y HDBSCAN (`05_density_dbscan_hdbscan.py`)

Ambos modelos se calibran sobre el mismo espacio de 15D PCA. Para DBSCAN se fijaron $\varepsilon = 3.4$ y $\text{MinPts} = 12$ a partir del gráfico de k-distancias; para HDBSCAN, `min_cluster_size=35` y `min_samples=10`. DBSCAN encontró **7 clústeres densos y 447 muestras de ruido (23.27 %)**; HDBSCAN encontró **2 clústeres y 104 muestras de ruido (5.41 %)**.

La **caracterización del ruido espectral** es informativa: de las 447 muestras que DBSCAN descarta, 222 son percusión, 137 guitarra y 88 piano. Se trata de audios ubicados en regiones de baja densidad, es decir, grabaciones atípicas o con timbres ambiguos. La **preservación de los núcleos densos** explica que DBSCAN obtenga el mejor índice de Davies-Bouldin (1.0903) y una silueta de 0.2878 calculada solo sobre los puntos no ruidosos: al excluir las muestras fronterizas, los grupos restantes están más separados. Esta ventaja es en parte artificial, pues evalúa un subconjunto más fácil de los datos.

HDBSCAN, con su criterio de estabilidad, fusiona los subgrupos de densidad comparable en dos grandes componentes (uno dominado por percusión y otro por instrumentos armónicos), con muy poco ruido. Como su partición coincide con la dicotomía percusivo/armónico pero no con las tres etiquetas, su ARI (0.0479) y su NMI (0.1923) son bajos; este resultado debe interpretarse con cautela, porque el cálculo trata la etiqueta de ruido (−1) como un grupo más. La Figura A4 compara ambos algoritmos.

4.4.4. Probabilístico: GMM (`06_gmm_probabilistic.py`)

El script evalúa BIC y AIC para $k \in \{2, \ldots, 8\}$ (Figura A3), ajusta el modelo definitivo con $k = 3$ y covarianza completa (`covariance_type="full"`) y exporta las probabilidades posteriores y los artefactos para la web. La certidumbre media, definida como el promedio del máximo de la responsabilidad γ_{ij}, es de **99.54 %**.

Este valor debe interpretarse con precaución. Con covarianzas completas en 15 dimensiones, las densidades gaussianas decaen muy rápido y las responsabilidades tienden a saturarse hacia 0 o 1, de modo que una certidumbre alta describe la **dureza de la asignación**, no su exactitud. La Tabla 7 lo confirma: el GMM mezcla piano y guitarra en dos clústeres con proporciones similares, aunque con certidumbre casi total.

Tabla 7
Matriz de contingencia del GMM ($k = 3$)

Clase real	Clúster 0	Clúster 1	Clúster 2
Sound_Drum	4	13	**676**
Sound_Guitar	257	**435**	8
Sound_Piano	**375**	140	13

4.4.5. Benchmark de reducción 2D (`07_dim_reduction_benchmark.py`)

Se proyectó la matriz estandarizada a dos dimensiones con cinco técnicas (Figura A5): PCA, SVD truncada, Factor Analysis, t-SNE (perplejidad 35) y UMAP ($n_{\text{neighbors}} = 25$, $\text{min_dist} = 0.3$).

- **PCA y SVD truncada** producen proyecciones prácticamente idénticas, como es esperable al trabajar con datos centrados. Separan la percusión a la derecha, pero superponen piano y guitarra en la región izquierda; solo una isla de guitarra aparece aislada en la parte inferior. La linealidad estricta impide desenredar la variedad.
- **Factor Analysis (PPCA)** modela una varianza específica de ruido gaussiano por variable y entrega una geometría similar con rotaciones; la separación entre piano y guitarra mejora ligeramente.
- **t-SNE** minimiza la divergencia de Kullback-Leibler entre similitudes gaussianas en alta dimensión y t-Student en baja dimensión (van der Maaten y Hinton, 2008).

Revela múltiples sub-islas locales, pero distorsiona las distancias globales: la separación entre islas no es interpretable.

- **UMAP** construye un grafo difuso de vecindad en alta dimensión y optimiza la disposición en baja dimensión minimizando la entropía cruzada difusa, con fundamentos en geometría riemanniana y topología algebraica (McInnes et al., 2018). Produce tres regiones diferenciadas (percusión, guitarra y piano) con subislas internas; piano y guitarra quedan separados en gran medida, lo que sugiere que su diferencia es no lineal y que los clústeres lineales de K-Means no la capturan en $k = 3$.

La sexta gráfica de la Figura A5 muestra la varianza acumulada del PCA, que alcanza 79.8 % con 15 componentes.

4.5. Consolidación de métricas

El script `03_evaluation/08_benchmark_metrics.py` recalcula todas las métricas sobre el mismo espacio de 15D PCA y exporta `05_reports/final_benchmark_metrics.csv`. En los modelos de densidad las métricas internas se calculan solo sobre los puntos no ruidosos (silueta núcleo). La Tabla 8 presenta los resultados oficiales.

Tabla 8
Benchmark consolidado de modelos de agrupamiento sobre 1,921 muestras (15D PCA)

Modelo	Clúst.	Ruido	Silueta ↑	CH ↑	DB ↓	ARI ↑	NMI ↑
K-Means ($k = 3$)	3	0 (0.0 %)	**0.2985**	**664.71**	1.3307	0.5370	**0.5877**
Ward ($k = 3$)	3	0 (0.0 %)	0.2880	636.46	1.3641	0.5408	0.5856
GMM ($k = 3$)	3	0 (0.0 %)	0.2098	534.58	1.8200	**0.5510**	0.5495
DBSCAN ($\varepsilon = 3.4$, MinPts $= 12$)	7	447 (23.27 %)	0.2878	310.32	**1.0903**	0.4063	0.5875
HDBSCAN (min $= 35$)	2	104 (5.41 %)	0.2478	368.02	1.3200	0.0479	0.1923

Nota. Clúst. = número de clústeres; CH = Calinski-Harabasz; DB = Davies-Bouldin. Negrita indica el mejor valor por columna. En DBSCAN y HDBSCAN las métricas internas excluyen el ruido. Fuente: `05_reports/final_benchmark_metrics.csv`. Véase la Figura A6.

Análisis comparativo.

Modelos exhaustivos. K-Means obtiene la mejor cohesión (silueta 0.2985, Calinski-Harabasz 664.71) y la mejor NMI (0.5877); Ward queda muy cerca (0.2880; 636.46) y alcanza una ARI ligeramente superior (0.5408), lo que indica que sus estructuras son casi equivalentes en este espacio. Ambos asignan todas las muestras, lo que los hace aptos para inferencia en tiempo real. El GMM logra la mayor ARI (0.5510), pero la menor silueta (0.2098) y el peor Davies-Bouldin (1.8200): sus clústeres elípticos de covarianza completa se solapan más en el espacio euclidiano, aunque se ajustan mejor a la partición real. La diferencia de ARI entre los tres modelos exhaustivos es de apenas 0.014, es decir, no hay una diferencia práctica en su concordancia con las etiquetas, y el criterio de elección debe basarse en otras propiedades (velocidad, probabilidades, interpretabilidad).

Modelos de densidad. DBSCAN logra el mejor Davies-Bouldin (1.0903), pero su Calinski-Harabasz (310.32) es el menor y descarta casi una cuarta parte de los datos; no es comparable de forma directa con los modelos exhaustivos. HDBSCAN con 2 clústeres es la partición más conservadora, y su baja ARI refleja la discrepancia de granularidad, no un error de implementación.

Lectura global. Ninguna partición alcanza concordancia alta con las etiquetas (ARI máxima de 0.551). La razón es estructural: piano y guitarra comparten regiones del espacio de descriptores, y la guitarra contiene subgrupos acústicamente distintos. Estos hallazgos son coherentes con la Tabla 4 y con las proyecciones 2D: los 71 descriptores separan muy bien la percusión de los instrumentos armónicos, pero la distinción entre piano y guitarra es más fina.

4.6. Inferencia por línea de comandos

El script `04_inference/09_predict_instrument.py` permite evaluar un archivo `.wav` o `.mp3` arbitrario desde la consola con `python 04_inference/09_predict_instrument.py --audio ruta.wav`. Carga los artefactos serializados de `web_app/models_bundle` (escalador, PCA y modelos), extrae el vector de 71 variables con el módulo canónico, lo proyecta a 15D y devuelve la asignación de K-Means y la del GMM, cada una con su instrumento por mayoría de clúster. Al compartir módulo y artefactos con la web, garantiza que la predicción por consola y la de la API coincidan. Una evaluación pendiente es ejecutar este flujo sobre las 80 muestras de `Metadata_Test.csv` (20 por clase, ya corregidas), como validación independiente con datos no vistos durante el ajuste.

4.7. Arquitectura de la plataforma web

La aplicación (`web_app/app.py`) es una API modular en Flask servida con Gunicorn. Su diseño responde a tres necesidades: desacoplar el frontend del backend, soportar usuarios concurrentes en un servidor de recursos limitados y entregar resultados interpretables.

Desacoplamiento frontend y backend. El backend expone endpoints REST bajo `/api/*` y habilita CORS únicamente para orígenes autorizados: el dominio del frontend desplegado en Netlify (`https://dat255.netlify.app`) y `localhost` para desarrollo. La Tabla 9 resume los endpoints.

Tabla 9
Endpoints de la API

Ruta	Método	Función
`/api/health`	GET	Verifica que el servicio esté activo
`/api/analyze_audio`	POST	Analiza el audio, devuelve instrumento, distribución, proyección 2D y notas CQT
`/api/audio_stream/<session_id>/<track_type>`	GET	Reproduce o descarga el stem armónico o percusivo

Validación y seguridad. El servidor limita el tamaño de carga a 15 MB, admite únicamente las extensiones `wav`, `mp3`, `ogg` y `flac`, captura los errores de decodificación y rechaza audios de menos de 300 ms. En el endpoint de streaming se sanea el identificador de sesión permitiendo solo caracteres alfanuméricos y guiones, lo que impide ataques de recorrido de rutas.

Control de concurrencia con UUID. Cada análisis genera un identificador `uuid.uuid4()` con el que se nombran los stems temporales (`<uuid>_harmonic.wav` y `<uuid>_percussive.wav`). Así, dos usuarios simultáneos nunca se sobrescriben los archivos. Una función de purga elimina los temporales con más de 10 minutos de antigüedad en cada solicitud, evitando el crecimiento indefinido del disco.

Despliegue. El servicio se ejecuta en Render con Gunicorn configurado con 1 *worker* y 4 *threads*, de modo que los modelos se carguen una sola vez en memoria y el consumo se ajuste al límite de 512 MB; los hilos permiten atender solicitudes concurrentes mientras otra espera operaciones de E/S.

Ventaneo temporal continuo. Promediar una pieza completa en un único vector produce una inferencia sesgada hacia el instrumento dominante y satura la probabilidad posterior. Por ello el backend recorre la señal con ventanas de 1.5 s y salto (*hop*) de 0.75 s, es decir, solapamiento del 50 %:

```
window_size, hop_size = int(sr * 1.5), int(sr * 0.75)
starts = list(range(0, total_samples - window_size, hop_size))
if starts[-1] + window_size < total_samples:        # evita omitir la cola
    starts.append(total_samples - window_size)
for st in starts:
    feats, *_ = extract_71_audio_features(y[st:st + window_size], sr)
    c = gmm_model.predict(pca_15d.transform(scaler.transform(feats.reshape(1, -1))))
    timeline_clusters.append(int(c[0]))
```

El porcentaje de ventanas asignadas a cada clúster se reporta como distribución de pertenencia temporal (por ejemplo, 45 % piano, 35 % percusión, 20 % guitarra). Además, se

aplica el modelo al vector global para obtener la probabilidad posterior (`predict_proba`), la confianza y la proyección a 2D de la pista, y se calcula el perfil de las tres notas dominantes a partir del cromagrama armónico.

Streaming de stems armónico y percusivo. El endpoint de streaming devuelve el WAV con `send_file`; con el parámetro `?download=true` se entrega como adjunto (`Pista_Armonica.wav` o `Pista_Percusiva.wav`). La interfaz permite la escucha comparativa A/B de ambos stems.

5. Conclusiones y Recomendaciones

5.1. Conclusiones

1. **El saneamiento de datos fue el hallazgo metodológico central.** La detección de 708 registros redundantes (700 violines idénticos a la percusión y 8 duplicados cruzados) transformó un problema aparente de cuatro clases en uno de tres familias físicas. Este hallazgo mostró que los modelos no fallaban, sino que reflejaban con exactitud la estructura real de los datos, y que las métricas externas calculadas contra etiquetas corruptas están acotadas (techo ARI $= 0.683$ con $k = 4$).
2. $k = 3$ **está respaldado empíricamente.** El coeficiente de silueta presenta un máximo claro en $k = 3$ (0.2985), por encima de $k = 4$ (0.2476), y es consistente con la estructura del corpus saneado. El método del codo no muestra un quiebre pronunciado y BIC/AIC siguen decreciendo con k, lo que revela subestructura interna sin alterar la conclusión principal.
3. **K-Means y GMM son complementarios.** K-Means ofrece la mejor cohesión geométrica, asignaciones deterministas y bajo costo de cómputo; el GMM aporta probabilidades de pertenencia y la mayor ARI (0.5510), a costa de una menor silueta y de probabilidades sobreconfiadas. Los modelos de densidad aportan una visión

complementaria: identifican y aíslan el 23.27 % de las muestras atípicas (DBSCAN) o consolidan la dicotomía percusivo/armónico (HDBSCAN).

4. **La representación de 15D PCA es sólida.** Con el 79.85 % de la varianza, el subespacio unifica la evaluación y separa con claridad la percusión (97.1 % de las baterías en un único clúster de K-Means). Sin embargo, no resuelve por sí sola la distinción entre piano y guitarra, cuya diferencia parece ser no lineal, como sugiere la separación observada en UMAP.
5. **La arquitectura web es reproducible y concurrente.** El módulo canónico garantiza coherencia entre entrenamiento, consola y producción; los UUID aíslan sesiones; y el ventaneo temporal produce una descripción más rica que la inferencia global.

5.2. Limitaciones

- **Piano y guitarra no se separan con $k = 3$.** El clúster mayoritario del piano contiene casi tantas guitarras (Tabla 5). Una etiqueta semántica por mayoría de clúster puede por tanto etiquetar como piano a una guitarra; la interfaz debería comunicar esa ambigüedad.
- **El etiquetado por mayoría es *post-hoc*.** Se declara formalmente que el entrenamiento fue 100 % no supervisado y que las etiquetas intervienen solo para interpretar los grupos y calcular ARI y NMI.
- **El escalador y el PCA se ajustaron con todo el corpus.** Es aceptable en un contexto no supervisado, pero implica que las métricas internas no provienen de una partición entrenamiento-prueba. Queda pendiente la validación con `Metadata_Test.csv`.

- **Calidad y procedencia del corpus.** Los audios no son grabaciones controladas; mezclan muestras sueltas, bucles y grabaciones de distinta duración, lo que introduce variabilidad no tímbrica.
- **Certidumbre del GMM sobreconfiada.** Un 99.54 % de certidumbre media no equivale a precisión.

5.3. Justificación metodológica: por qué no se separó la voz

Un requisito natural en un sistema de separación de fuentes es aislar la voz humana del acompañamiento. Este proyecto deliberadamente no lo implementa, por las razones técnicas siguientes.

1. El supuesto de HPSS es estacionario frente a transitorio, no instrumento frente a voz. HPSS clasifica cada región tiempo-frecuencia según su continuidad: horizontal (estacionaria) o vertical (transitoria). No contiene ningún modelo de fuente. La voz humana es una señal mixta que incumple la premisa de pertenecer a una sola componente: las vocales sostenidas y sus formantes aparecen como estructuras horizontales y se asignan al **stem armónico**, junto con el piano, la guitarra y cualquier sonido tonal; las consonantes oclusivas y fricativas (/p/, /t/, /k/, /s/) son transitorias de banda ancha y se asignan al **stem percusivo**, junto con el bombo y los platillos. La voz queda así **fracturada** entre ambos stems, y ninguno contiene la voz completa ni solo la voz.

2. Aislar la voz exige conocimiento de la fuente. Para separar la voz de un acompañamiento armónico hace falta un modelo que codifique qué es una voz: su estructura de formantes, su vibrato, su continuidad melódica y su relación armónica entre parciales. En el aprendizaje no supervisado clásico, esto sería una descomposición ciega (por ejemplo, NMF sin restricciones o REPET), que funciona solo si la voz es el elemento no repetitivo sobre un

acompañamiento periódico (Rafii y Pardo, 2013). Los métodos que alcanzan una separación de voz de calidad utilizable en música comercial son redes profundas entrenadas de manera supervisada, como Spleeter (Hennequin et al., 2020) y Demucs (Défossez et al., 2021), entrenadas sobre corpus con pistas separadas como MUSDB18 (Rafii et al., 2017).

3. Usar esos modelos desvirtuaría la naturaleza del proyecto. Incorporar Demucs o Spleeter introduciría un componente de *deep learning* supervisado con miles de horas de ejemplos etiquetados y arquitecturas opacas. El objetivo declarado del proyecto es demostrar que descriptores físicos transparentes y algoritmos clásicos de agrupamiento son suficientes para estructurar el timbre sin supervisión. Un módulo supervisado cambiaría esa conclusión: se atribuiría parte del resultado a una caja negra preentrenada.

4. Alcance coherente. El sistema ofrece, en cambio, una separación **armónico-percusiva** (melodía sostenida frente a ritmo y transitorios) con un fundamento físico completo y reproducible. Cualquier extensión hacia separación vocal debe presentarse explícitamente como un módulo supervisado y opcional, evaluado por separado.

5.4. Recomendaciones y trabajo futuro

1. **Factorización Matricial No Negativa (NMF) semi-supervisada.** NMF descompone el espectrograma de magnitud como $\mathbf{V} \approx \mathbf{WH}$, con $\mathbf{W} \geq 0$ (bases espectrales) y $\mathbf{H} \geq 0$ (activaciones temporales), mediante las reglas multiplicativas de Lee y Seung (1999). Su variante semi-supervisada fija parte del diccionario $\mathbf{W}$ con plantillas de timbres aprendidos de los clústeres de este proyecto (percusión, guitarra y piano) y deja libres las demás bases, lo que permitiría separar más de dos componentes conservando la interpretabilidad y un bajo costo computacional.

2. **Autoencoders variacionales convolucionales (β-VAE).** Un β-VAE (Higgins et al., 2017) sobre el espectrograma Mel o el cromagrama aprendería una representación latente con factores desentrelazados, cuya pérdida es $\mathcal{L} = \mathbb{E}_{q(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x}|\mathbf{z})] - \beta\, D_{\mathrm{KL}}\left(q(\mathbf{z}|\mathbf{x}) \,\|\, p(\mathbf{z})\right)$ (Kingma y Welling, 2014). El espacio latente resultante, de pocas dimensiones, podría alimentar a K-Means o GMM como sustituto de PCA y capturar la no linealidad que separa piano de guitarra; esto conservaría el agrupamiento no supervisado, aunque con una etapa de representación neuronal que debe declararse como tal.
3. **Ampliación y depuración del corpus.** Reemplazar la clase *Sound_Violin* con violines auténticos de cuerda frotada permitiría evaluar la discriminación entre ataques percutidos (piano), punteados (guitarra) y frotados (violín), y recuperar un $k = 4$ con sustento físico.
4. **Validación independiente.** Ejecutar el pipeline sobre `Metadata_Test.csv` y reportar el desempeño con datos no vistos; ajustar escalador y PCA solo con el conjunto de entrenamiento.
5. **Exploración de variantes del modelo.** Probar GMM con covarianzas diagonales o esféricas, regularización de covarianza y estimación del número de grupos con silueta por muestra; y reportar intervalos de confianza de las métricas mediante múltiples semillas.
6. **Mejoras de producto.** Mostrar la ambigüedad piano/guitarra en la interfaz, promediar `predict_proba` por ventana en lugar de la clase dura, y agregar el módulo REPET para estimar patrones periódicos del acompañamiento.

6. Bibliografía

Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control, 19*(6), 716–723. https://doi.org/10.1109/TAC.1974.1100705

Arthur, D., y Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. En *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms* (pp. 1027–1035). Society for Industrial and Applied Mathematics.

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Brown, J. C. (1991). Calculation of a constant Q spectral transform. *The Journal of the Acoustical Society of America, 89*(1), 425–434. https://doi.org/10.1121/1.400476

Caliński, T., y Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics, 3*(1), 1–27. https://doi.org/10.1080/03610927408827101

Campello, R. J. G. B., Moulavi, D., y Sander, J. (2013). Density-based clustering based on hierarchical density estimates. En *Advances in Knowledge Discovery and Data Mining: PAKDD 2013* (pp. 160–172). Springer. https://doi.org/10.1007/978-3-642-37456-2_14

Davies, D. L., y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909

Davis, S., y Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing, 28*(4), 357–366. https://doi.org/10.1109/TASSP.1980.1163420

Défossez, A., Usunier, N., Bottou, L., y Bach, F. (2021). *Hybrid spectrogram and waveform source separation* [Preimpresión]. arXiv. https://arxiv.org/abs/2111.03600

Dempster, A. P., Laird, N. M., y Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological), 39*(1), 1–38.

Ester, M., Kriegel, H.-P., Sander, J., y Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)* (pp. 226–231). AAAI Press.

FitzGerald, D. (2010). Harmonic/percussive separation using median filtering. En *Proceedings of the 13th International Conference on Digital Audio Effects (DAFx-10)*. Graz, Austria.

Hennequin, R., Khlif, A., Voituret, F., y Moussallam, M. (2020). Spleeter: A fast and efficient music source separation tool with pre-trained models. *Journal of Open Source Software, 5*(50), 2154. https://doi.org/10.21105/joss.02154

Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., y Lerchner, A. (2017). beta-VAE: Learning basic visual concepts with a constrained variational framework. En *International Conference on Learning Representations (ICLR 2017)*.

Hubert, L., y Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Jolliffe, I. T., y Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), Artículo 20150202. https://doi.org/10.1098/rsta.2015.0202

Kingma, D. P., y Welling, M. (2014). Auto-encoding variational Bayes. En *International Conference on Learning Representations (ICLR 2014)*.

Lee, D. D., y Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization. *Nature, 401*(6755), 788–791. https://doi.org/10.1038/44565

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory, 28*(2), 129–137. https://doi.org/10.1109/TIT.1982.1056489

McFee, B., Raffel, C., Liang, D., Ellis, D. P. W., McVicar, M., Battenberg, E., y Nieto, O. (2015). librosa: Audio and music signal analysis in Python. En *Proceedings of the 14th Python in Science Conference* (pp. 18–25). https://doi.org/10.25080/Majora-7b98e3ed-003

McInnes, L., Healy, J., y Melville, J. (2018). *UMAP: Uniform manifold approximation and projection for dimension reduction* [Preimpresión]. arXiv. https://arxiv.org/abs/1802.03426

Müller, M. (2015). *Fundamentals of music processing: Audio, analysis, algorithms, applications*. Springer. https://doi.org/10.1007/978-3-319-21945-5

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rafii, Z., Liutkus, A., Stöter, F.-R., Mimilakis, S. I., y Bittner, R. (2017). *The MUSDB18 corpus for music separation* [Conjunto de datos]. Zenodo. https://doi.org/10.5281/zenodo.1117372

Rafii, Z., y Pardo, B. (2013). Repeating pattern extraction technique (REPET): A simple method for music/voice separation. *IEEE Transactions on Audio, Speech, and Language Processing, 21*(1), 73–84. https://doi.org/10.1109/TASL.2012.2213249

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics, 6*(2), 461–464. https://doi.org/10.1214/aos/1176344136

van der Maaten, L., y Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579–2605.

Vinh, N. X., Epps, J., y Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. *Journal of Machine Learning Research, 11*, 2837–2854.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

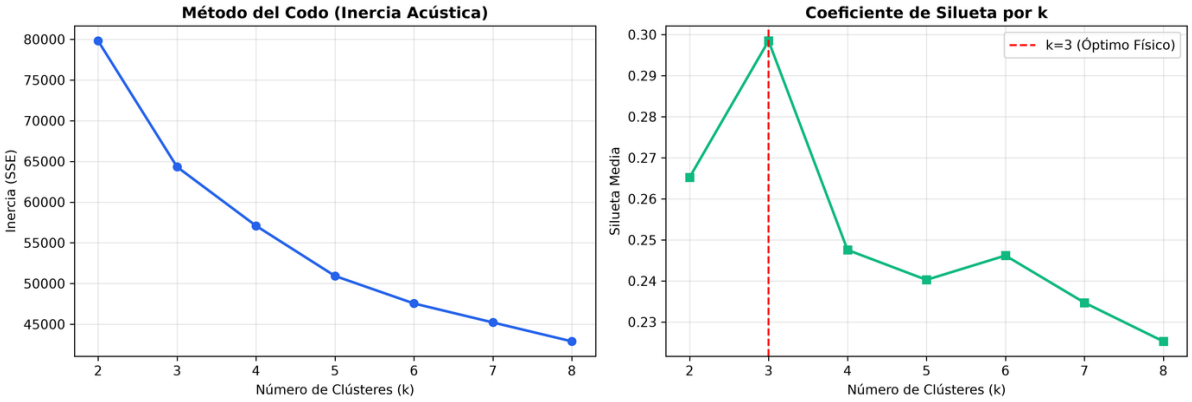
7. Anexos

Anexo A. Evidencia experimental y gráficos generados

Las figuras siguientes provienen de la carpeta `05_reports/` del repositorio y fueron generadas por los scripts del pipeline con resolución de 300 dpi.

Figura A1

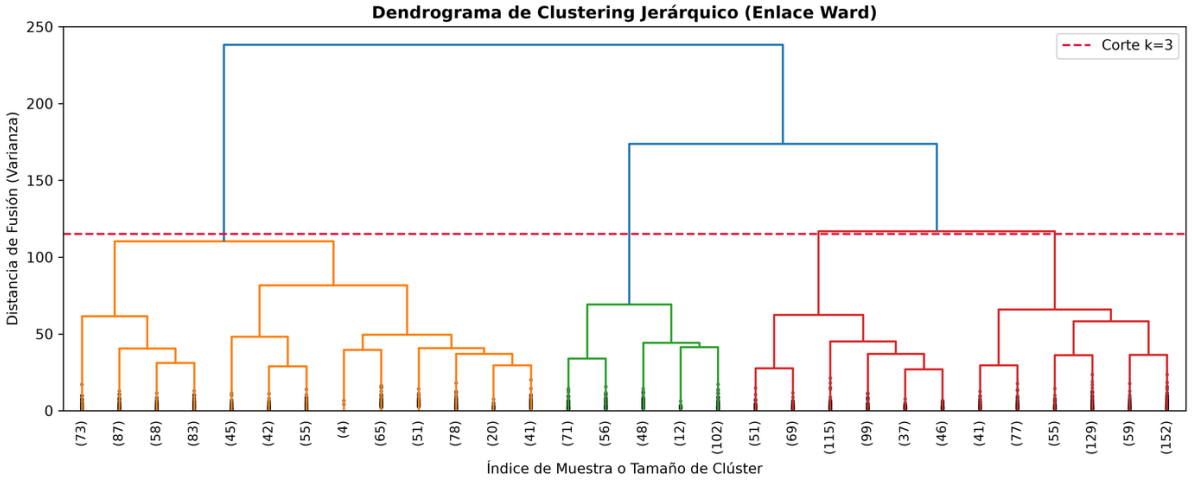
Método del codo e índice de silueta de K-Means



Nota. Archivo: `05_reports/kmeans_elbow_silhouette.png`. El máximo de silueta se alcanza en $k = 3$.

Figura A2

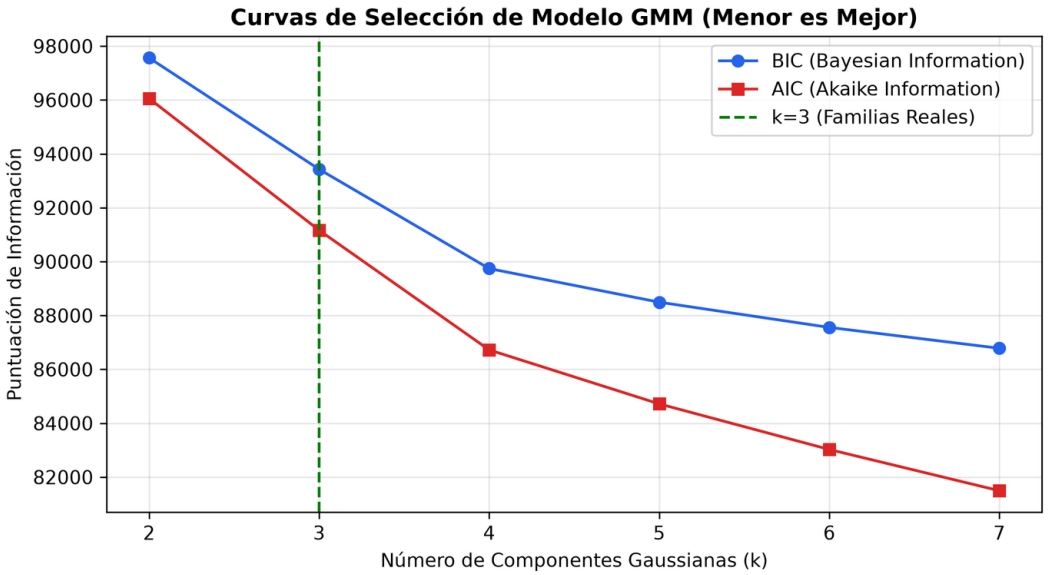
Dendrograma jerárquico de Ward sobre el espacio de 15D PCA



Nota. Archivo: `05_reports/hierarchical_dendrogram.png`.

Figura A3

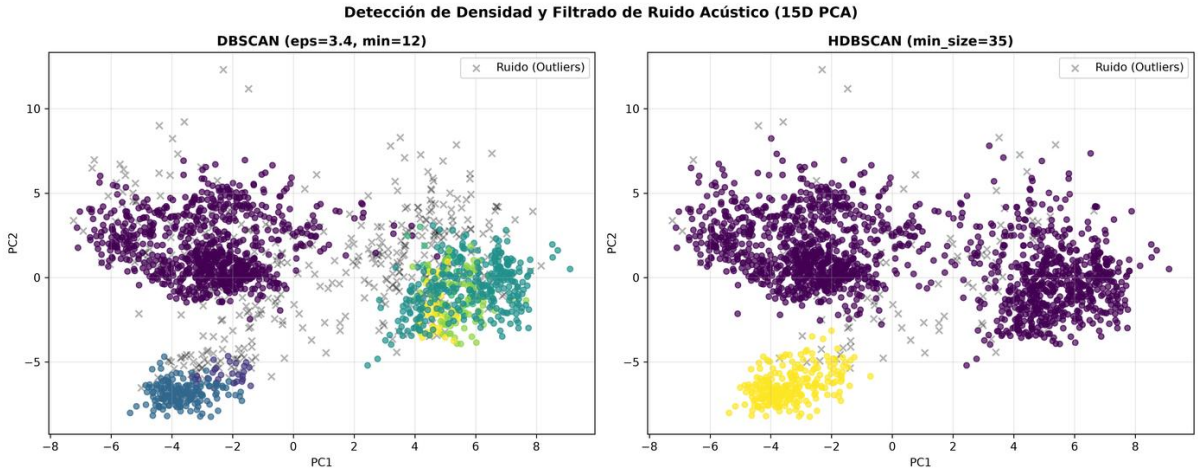
Curvas de selección BIC y AIC del modelo de mezclas gaussianas



Nota. Archivo: `05_reports/gmm_bic_aic_curve.png`. Menor valor indica mejor ajuste penalizado.

Figura A4

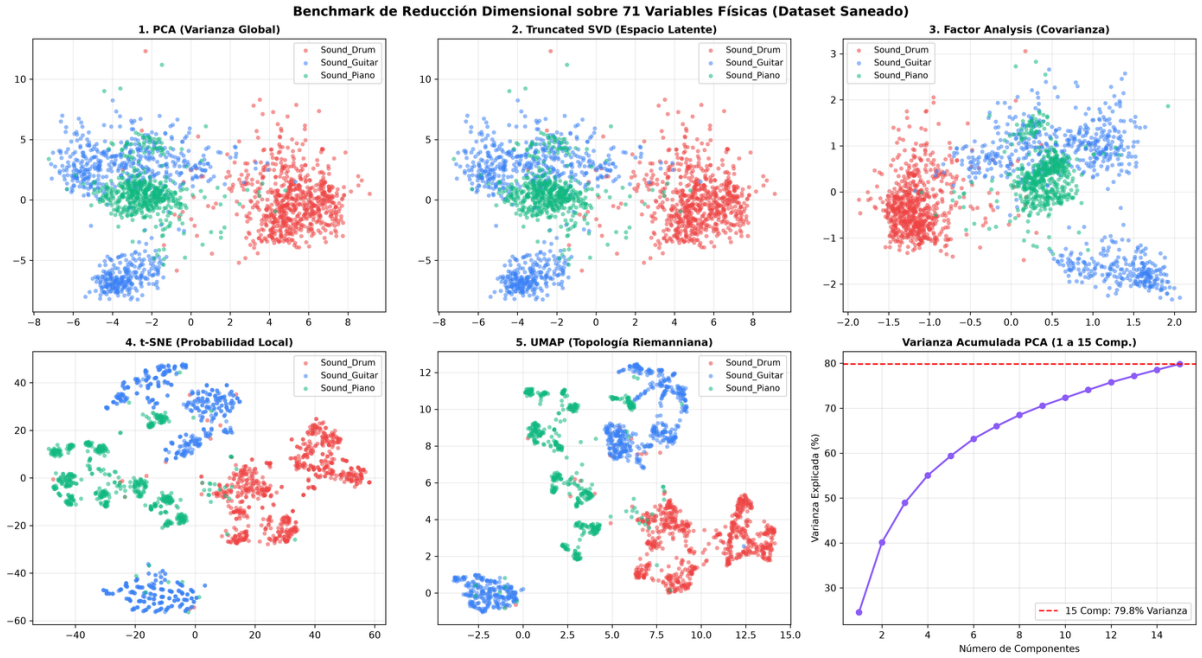
Filtrado de densidad y ruido: DBSCAN frente a HDBSCAN



Nota. Archivo: `05_reports/density_comparison.png`.

Figura A5

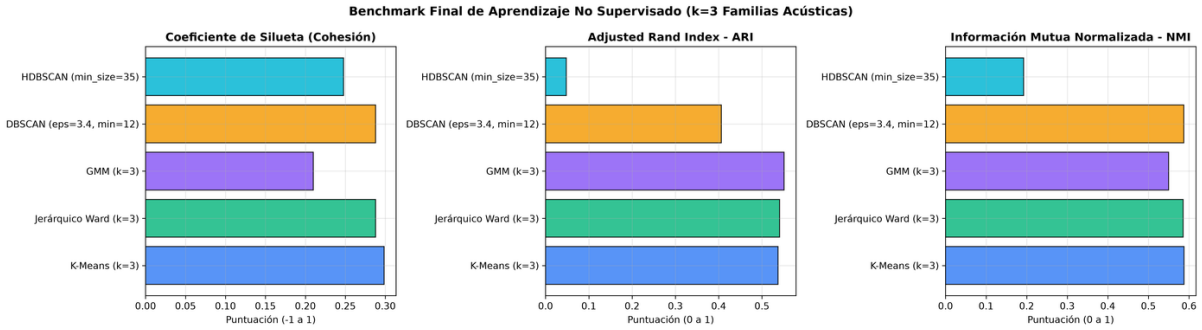
Benchmark de reducción dimensional a 2D sobre las 71 variables físicas



Nota. Archivo: `05_reports/dim_reduction_comparison.png`. Incluye PCA, SVD truncada, Factor Analysis, t-SNE, UMAP y la varianza acumulada del PCA.

Figura A6

Cuadro multimétrico comparativo de los modelos de agrupamiento



Nota. Archivo: `05_reports/benchmark_comparison_charts.png`.

Anexo B. Evidencias de la plataforma web en producción

Figura B1

Interfaz principal de la plataforma web

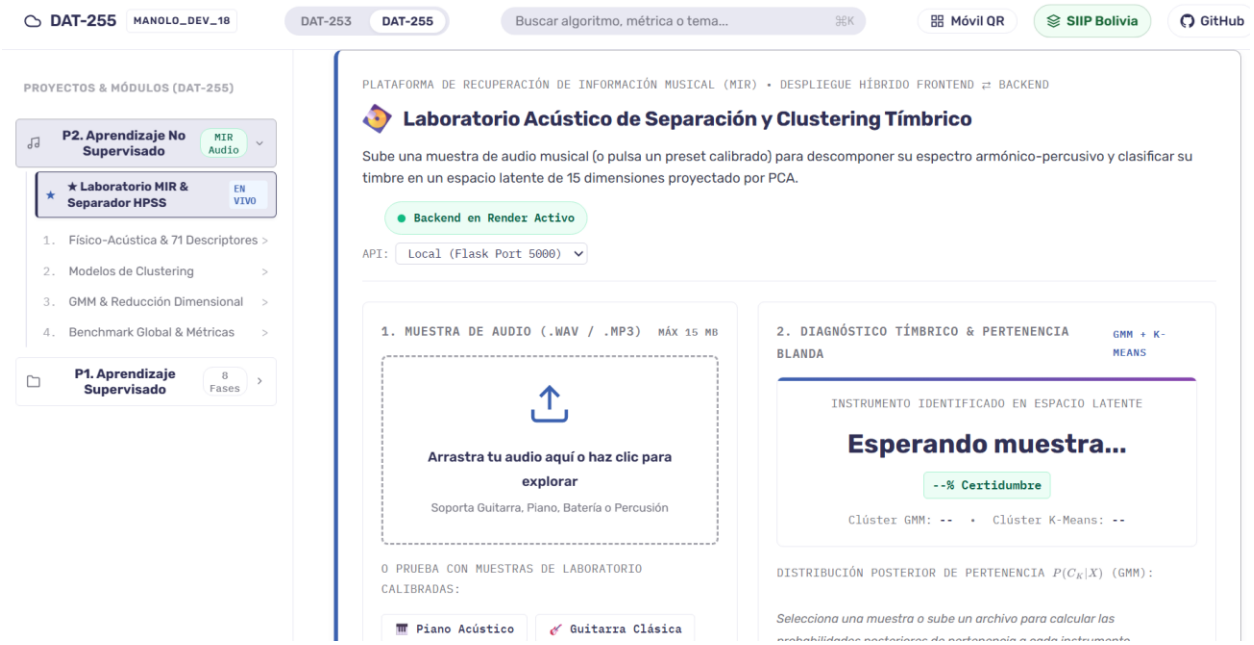


Figura B2

Reproducción y descarga de los stems armónico y percusivo

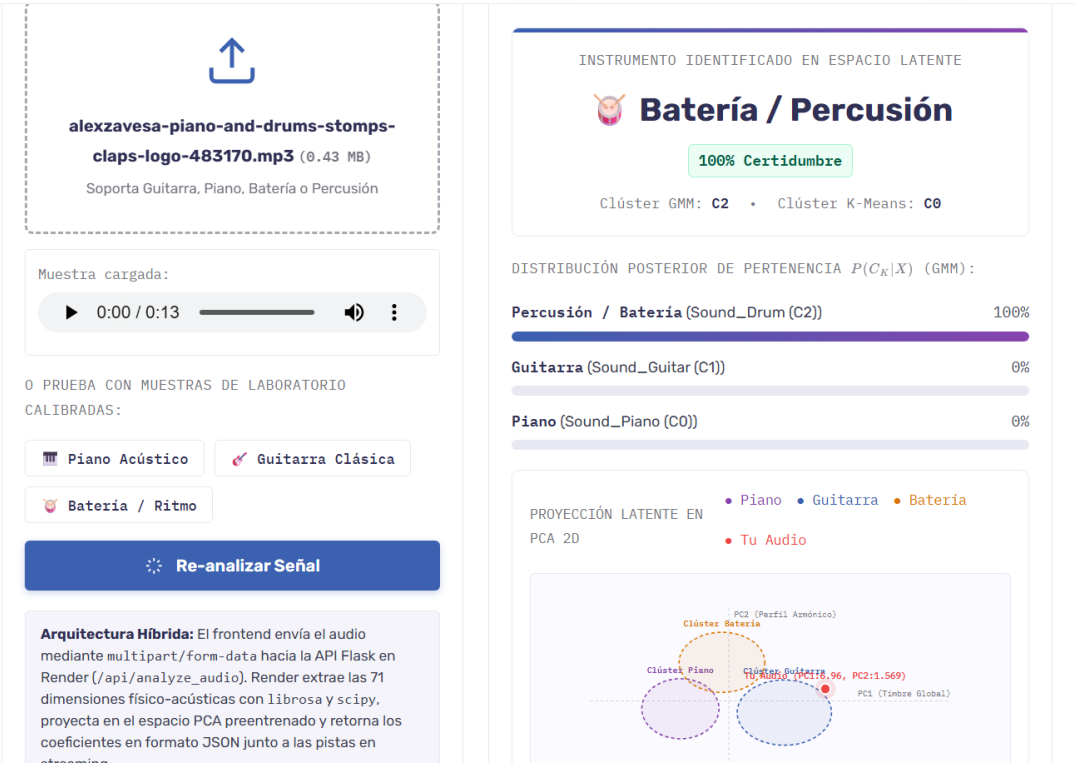


Figura B3

Cromagrama Constant-Q y detección de notas dominantes

